

アーキテクチャ概要

S-01 Aegis Omnis v130.4 - システム構成

システム構成図（処理フロー）

【入力】 ユーザーテキスト / コマンド (/a /s /chess /mj ...)



【入力処理層】 sanitize() → normalize() → プロンプトインジェクション多層防御 Layer1: XMLタグ無効化 Layer2: 役割変更パターン除去 Layer3: ゼロ幅文字除去



【複雑度推定 & モデル選択】 estimate_complexity() → gemma3:1b (挨拶・短文) / 4b (標準) / 12b (哲学・長文・deep思考)



RAG パイプライン

会話 & ペルソナ層

ゲーム & ツール層

将棋AI: Negamax+
MCTS 麻雀: HTML
ReActエージェン
SPI対策機能



【BackgroundOptimizer】 120秒間隔 RAGキャッシュ管理 / 温度自動調整 / プロンプト改善 / 学習データ保存



【出力 & 永続化】 ストリーミング出力 → ChromaDB / s01_state.json / 会話履歴

セキュリティ・運用の工夫

カテゴリ	実装内容
プロンプトインジェクション防御	3層防御: XMLタグ無効化 / 役割変更パターン正規表現除去 / ゼロ幅文字除去 (Layer3先行実行でバイパス対策)
SSRF防御	プライベートIPレンジ全域 + IPv6マップドアドレス (::ffff:127.x.x.x) まで検査。リダイレクト先も再検査。
ASTベース電卓	astモジュールでホワイトリスト外ノードを拒否。type()・repr()も除外。eval()不使用。
スレッドセーフ設計	TEMP_VOICE / ベクトルDB辞書 / IDインクリメント / HyDEキャッシュに全てthreading.Lockを適用。
速度最適化 (v130.4)	num_ctx半減 / RAGプリフェッチ / HyDE並列化 / 8文字バッファ書き出しなど11項目。

技術スタック

領域	技術・ライブラリ
LLMバックエンド	Ollama (gemma3:1b/4b/12b)
ベクトルDB	ChromaDB
RAG	BM25 (rank-bm25), sentence-transformers (Cross-Encoder), HyDE
ゲームAI	Negamax, MCTS, curses (将棋・チェス), HTML生成 (麻雀)
並列処理	asyncio, threading, ThreadPoolExecutor
動作環境	Ryzen 7 5700U / RAM 32GB / CPUオンリー / クラウド不使用